

BADANIA OPERACYJNE



AGH

Skład zespołu:

Tomasz Lichoń

Tomasz Pałys

Jakub Sawicki

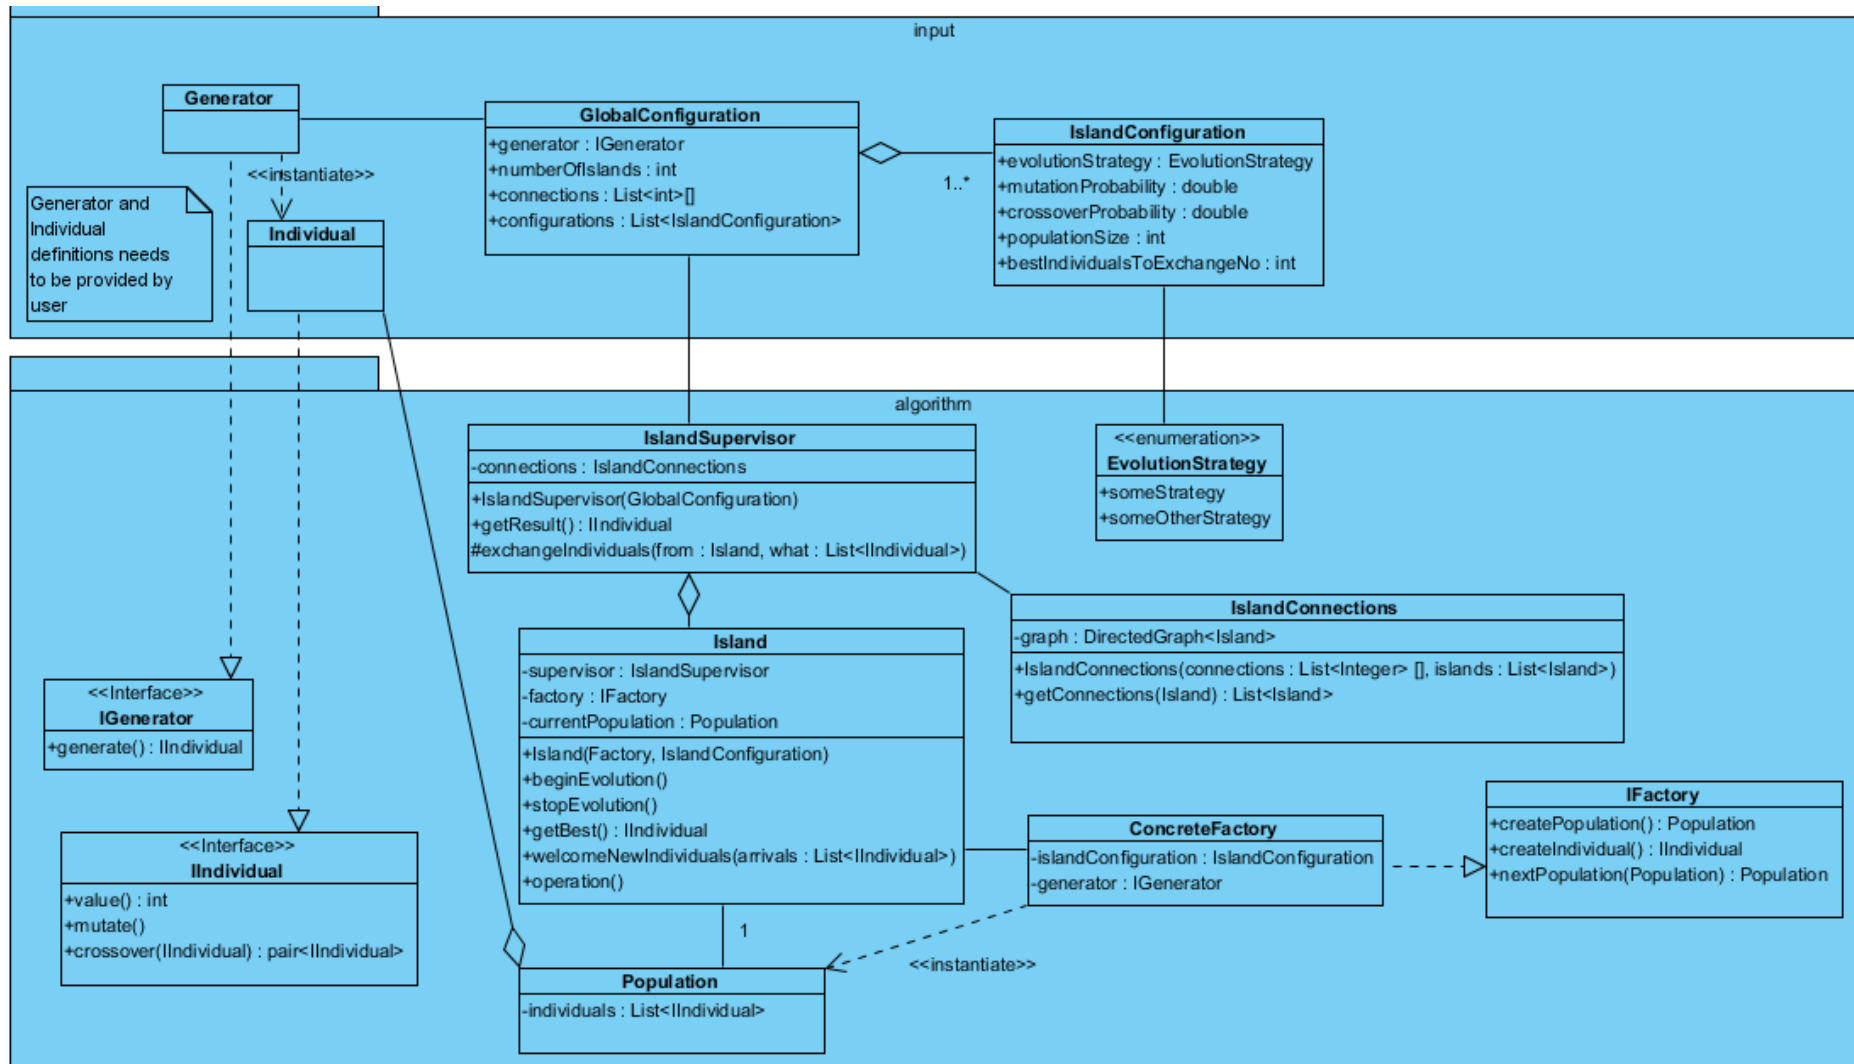
Natalia Potoczny

Mateusz Radko

Konrad Zuchowicz

Łukasz Cieśla

1. Diagram UML



2. Architektura systemu

Ogólny zarys systemu możemy zobaczyć na załączonym diagramie klas UML. Widać wyraźny podział między częścią konfiguracyjną zależną od użytkownika (input) i częścią algorytmiczną która jest parametryzowana przez konkretną konfigurację.

Input:

W celu skorzystania z systemu użytkownik musi dostarczyć klasy implementujące interfejsy `Iindividual` i `IGenerator`. Podstawą jest `Iindividual` w którym użytkownik powinien zdefiniować sposób reprezentacji konkretnego argumentu, metodę która pozwala wyliczyć wartość funkcji której ekstremum mamy badać, oraz dostarczyć podstawowe operacje takie jak mutacja, krzyżowanie czy zduplikowanie osobnika.

Klasy te są bezpośrednio związane z problemem, oprócz tego wymagamy wyspecyfikowania pełnej konfiguracji działania systemu, co obejmuje:

- instancję obiektu generatora zdolnego generować losowe osobniki
- zmienną logiczną `maximize`, informującą czy mamy szukać minimum czy maksimum
- czas ewolucji (jak długo algorytm ma szukać rozwiązania)
- listę sąsiedztwa dla grafu połączeń między wyspami
- konfigurację dla każdej z wysp, która obejmuje:
 - Strategię ewolucyjną wyspy (którąś z tych udostępnianych przez system)
 - prawdopodobieństwo mutacji
 - prawdopodobieństwo krzyżowania
 - rozmiar populacji
 - ilość osobników wybieranych co ewolucję w celu rozmnożenia
 - ilość osobników wymienianych z innymi wyspami

Algorithm:

Sercem systemu jest `IslandSupervisor`, który ustala graf połączeń na podstawie konfiguracji użytkownika, tworzy poszczególne wyspy z odpowiednimi konfiguracjami, mówi kiedy mają rozpocząć i kończyć pracę, oraz pośredniczy w komunikacji między nimi.

W naszym przypadku wyspy implementowane są przy pomocy odrębnych wątków, można jednak w prosty sposób wydzielić interfejsy wykorzystane przy komunikacji poziomemu `slave` – `supervisor` i przenieść je na osobne maszyny tworząc system rozproszony.

Na każdej z wysp ewolucja postępuje według tego samego, prostego algorytmu:

1. Dodaj do populacji przybywające na wyspę osobniki
2. Wyślij swoje najlepsze osobniki do supervisor'a w celu przekazania ich innym wyspą
3. Przeprowadź ewolucję przechodząc do następnej populacji
4. Zaktualizuj informację o najlepszym osobniku

Całość informacji o konkretnym sposobie prowadzenia ewolucji posiada `supervisor` który każdej z wysp przyporządkowuje konkretną fabrykę odpowiedzialną za generację nowych

populacji. Wyspy natomiast operują na takim poziomie abstrakcji, że nie są świadome istnienia różnych strategii ewolucyjnych, korzystają tylko ze znanego sobie interfejsu `IFactory`.

Kluczowym z punktu widzenia całości systemu jest algorytm fabryki. Musi ona być w stanie wygenerować populację początkową, oraz na podstawie zdefiniowanej konfiguracji przeewoluować jedną populację w drugą. Trzon każdej z fabryk jest nakreślony w klasie `AbstractFactory`, szczególnie istotna jest metoda `nextPopulation(Population parent)`, która definiuje schemat każdej z przeprowadzanych ewolucji, jest on następujący:

1. Wybierz osobników ojców
2. Krzyżuj ojców aż uzyskasz pełną populację
3. Mutuj wybrane osobniki
4. Zwróć tak stworzone osobniki jako nową generację

Metoda selekcji zależna jest od konkretnej strategii ewolucyjnej, aktualnie wspieramy pięć strategii: `Roulette`, `Stochastic`, `Tournament`, `LinearRanked`, `Truncation`. Każdej z nich odpowiada osobna fabryka, która jako jednostka przekazywana wyspie kryje w sobie całą logikę związaną z czystym algorytmem ewolucyjnym.

Nowe strategie mogą być w prosty sposób dodawane poprzez zdefiniowanie konkretnej fabryki. Można sobie nawet wyobrazić sytuację w której użytkownik system w zależności od potrzeb definiuje własny sposób ewolucji dostosowany do charakterystyki problemu.

W następnym rozdziale znajdują się opisy zdefiniowanych przez nas strategii

3. Algorytmy

Selekcja ma na celu wyłonienie osobników, które będą podlegać krzyżowaniu. Zaimplementowane metody selekcji:

Metoda ruletki

Wybieramy n osobników n razy losując liczbę z zakresu od 0 do sumy wskaźników fitness dla całej populacji.

Prawdopodobieństwo, czy wybierzemy danego osobnika zależy liniowo od jego wskaźnika fitness. Może się zdarzyć, że


dominujący osobnik zostanie wybrany kilka razy.

Metoda stochastyczna

W celu zmniejszenia dominacji najlepszych osobników w wynikowych populacjach losujemy tylko jedną

liczbę, natomiast wybieramy n osobników w następujący sposób:

długość paska określa wskaźnik fitness danego osobnika



Losowo wybieramy pierwszy wskaźnik, a następnie akceptujemy osobniki w odpowiednich odstępach.

Dzięki temu zmniejszony jest elitizm w wynikowych populacjach.

Metoda turniejowa

N razy dokonujemy losowania dwóch osobników z populacji, a następnie porównujemy ich fitness.

Z prawdopodobieństwem równym presji środowiska (liczba od 0 do 1, praktycznie od 0.5) wybieramy lepszego z nich.

Metoda Rankingowa

Algorytm selekcji opiera się na wyznaczeniu liniowej funkcji przypisującej prawdopodobieństwo wyboru kandydata. Sortujemy populację od najlepszego do najgorszego kandydata na rozwiązanie, prawdopodobieństwo wyboru poszczególnego rozwiązania liczymy według wzoru:

$$P(x) = \frac{N + 1 - x}{N(N + 1)}$$

gdzie x to pozycja w rankingu, a N opisuje licznosc zbioru kandydatów.

Następnie przedział [0,1] dzielimy według wzoru otrzymując N przedziałów dla każdego kandydata $[0, \frac{N}{N(N+1)}), [\frac{N}{N(N+1)}, \frac{N}{N(N+1)} + \frac{N-1}{N(N+1)}), \dots, [\sum_{i=2}^N \frac{i}{N(N+1)}, 1]$.

Losujemy k-krotnie liczbę z przedziału [0,1] i do zbioru dodajemy kandydata w przedziale, którego znajdzie się randomowa liczba. (Podobnie jak w Roulette Selection)

Truncation method

Algorytm działa analogicznie do Linear Ranked Selection jednak odrzucamy od 10 do 50% procent najgorszych kandydatów.

Krzyżowanie

Osobniki są losowo dobierane w pary i wykonywane jest na nich krzyżowanie. Operacja ta dokonywana jest

na już wyselekcjonowanych osobnikach, do których na koniec całej operacji dodawana jest nowa pula ich dzieci.

Tzn. osobniki wyselekcjonowane pozostają w populacji, a nie tylko ich dzieci.

Mutacja

Z określonym w dokumentacji prawdopodobieństwem każdy z osobników mutuje.